

作业一：图像边缘检测与分类算法研究

课程：大数据原理与技术

年级	2023级	专业（方向）	计算机技术与科学
学号	22344023	姓名	曾健
电话	13672733896	Email	zengj233@mail2.sysu.edu.cn

1. 实验目标

使用Python+OpenCV实现以下功能：

- 任选一张图像，使用边缘检测算法Sobel检测图像边缘。展示原图像和分割后的图像。
- 选择一种机器学习方法（支持向量机（SVM）、决策树等）和一种深度学习方法（MLP、CNN等），实现图像分类，数据集任选（如MNIST、CIFAR-10），对比两种方法的准确率和计算效率。

2. 实验环境

- 硬件环境：
 - 处理器 (CPU): AMD EPYC 7502 32-Core Processor
 - 图形处理器 (GPU): NVIDIA GeForce RTX 3090 (24GB 显存)
 - 运行内存 (RAM): 503GB
- 软件环境：
 - 操作系统 (OS): Linux 4.15.0-213-generic
 - Python 版本: 3.9.23
 - 核心库版本：
 - PyTorch: 2.6.0 + cu124 / Torchvision: 0.21.0 + cu124
 - OpenCV: 4.13.0
 - Scikit-learn: 1.6.1
 - Matplotlib: 3.9.4 / NumPy: 2.0.2

3. 实验内容一：基于Sobel算子的边缘检测

3.1 算法原理

Sobel算子是一种离散微分算子，它结合了高斯平滑和微分求导。该算子通过计算图像亮度函数的梯度近似值来寻找边缘。其核心是两个 3×3 的卷积核 G_x 与 G_y ，分别对应水平和垂直方向：


$$G_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}, \quad G_y = \begin{bmatrix} +1 & +2 & +1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

在实际实现中，首先将图像转换为灰度图，分别与 G_x 、 G_y 进行卷积得到两个方向的梯度响应，再通过线性加权融合的方式将两者合并为最终的边缘强度图。相比直接计算 $G = \sqrt{G_x^2 + G_y^2}$ ，加权融合在保证边缘轮廓清晰的同时计算更高效。

3.2 实验步骤

1. **图像读取与灰度化**：使用 `cv2.imread()` 读取原始图像，并通过 `cv2.cvtColor()` 将RGB图像转换为单通道灰度图，减少计算量，突出亮度变化信息。
2. **梯度计算**：调用 `cv2.Sobel()` 函数计算 x 和 y 方向的梯度，输出数据类型设为 `cv2.CV_64F` 以保留负梯度信息。
3. **梯度绝对值转换**：使用 `cv2.convertScaleAbs()` 将浮点型梯度结果转换为 `uint8` 类型，便于后续显示和融合。
4. **梯度融合**：通过 `cv2.addWeighted()` 将水平和垂直梯度以0.5 : 0.5的权重进行线性叠加，得到最终的边缘检测结果。


3.3 实验结果分析



对于结构清晰的图形（如二次元人像），Sobel算子能够精准地提取出人物的轮廓、发丝以及眼镜和衣物的线条。由于原图对比度较高，边缘结果非常干净且连贯，有效地保留了图像的主要特征信息。



对于细节极其丰富的图像（如校园地图），Sobel算子展现了极高的敏感度，不仅勾勒出了大型建筑的轮廓，连细小的道路边缘、植被区域的边界甚至文字标注都得到了清晰的体现。这证明了Sobel算子在处理高频细节场景时的有效性。




对于复杂自然场景（如带有检测框的公园长椅），结果显示，长椅的密集格栅被完整捕捉，且由于Sobel算子对亮度突变极度敏感，原图中的蓝色和红色检测框（作为极强的边缘）在处理后呈现为极其明亮的白线。同时，背景树木的纹理也被部分提取，呈现出一种独特的质感。

在计算效率方面，由于Sobel算子采用的是 3×3 的矩阵卷积运算，处理速度极快，在普通CPU环境下即可实现实时处理，满足一般计算机视觉任务对实时性的要求。

为了获得更纯净的边缘结果，我们可以调用 `cv2.threshold()` 函数，将阈值设为50。该步骤将梯度强度大于50的像素设为255（白色），其余设为0（黑色），有效地去除了背景中的微弱噪声，使边缘轮廓更加清晰、鲜明。

```
_, sobel_combined = cv2.threshold(sobel_combined, 50, 255, cv2.THRESH_BINARY)
```

效果如下：



4. 实验内容二：图像分类方法对比 (SVM vs. CNN)

4.1 数据集说明

- **MNIST**: 手写数字数据集，包含60,000张训练图像和10,000张测试图像，每张图像为28×28的灰度图，共10类 (0~9)。
- **CIFAR-10**: 彩色物体数据集，该数据集包含了60,000张32×32像素的彩色RGB 图像，均匀分布在10个不同的物体类别中。其中50,000张图像构成训练集，另外10,000张作为测试集。而这10个类别涵盖了常见的物体类型，包括：飞机 (airplane)、汽车 (automobile)、鸟 (bird)、猫 (cat)、鹿 (deer)、狗 (dog)、青蛙 (frog)、马 (horse)、船 (ship) 和卡车 (truck)。

4.2 算法实现模型

1. 机器学习 (SVM):

- **核函数**: 采用**线性核 (Linear Kernel)**。
- **参数配置**: 设置容差 `tol=1e-3`，最大迭代次数为1000次。
- **数据预处理**: 将图像像素值归一化至 $[0, 1]$ 区间，并展平为一维向量作为输入特征。
- **样本规模**: 由于SVM在高维数据上的训练复杂度较高，实验对CIFAR-10数据集选取了5,000个样本作为训练子集，MNIST则使用全集。

2. 深度学习 (CNN):

- **网络架构 (CNN)**: 设计了一个包含两层卷积和两层全连接的卷积神经网络:

```
Input (1×28×28 或 3×32×32)
→ Conv2d (out_channels=32, kernel_size=3, stride=1) → ReLU
→ MaxPool2d (kernel_size=2)
→ Conv2d (out_channels=64, kernel_size=3, stride=1) → ReLU
→ MaxPool2d (kernel_size=2)
→ Flatten
→ Linear (out_features=128) → ReLU
→ Linear (out_features=10)
```

- **超参数设置**:

- **优化器**: Adam, 学习率 `lr=0.001`。

- **损失函数**：交叉熵损失CrossEntropyLoss。
- **训练配置**：Batch Size为128，共训练10个Epoch。

4.3 实验结果分析

实验设置说明：

为了对比的严谨性，本实验对数据集进行了如下处理：

- **MNIST**：使用全部60,000张训练图进行CNN和SVM训练。
- **CIFAR-10**：由于彩色图像维度更高（32×32×3），SVM 全量训练耗时极长，因此统一抽取前5,000张图像作为CNN和SVM的共同训练集，测试则均在全量10,000张测试集上进行。

两种算法在两种测试集结果：


数据集	算法	最终准确率	训练时间
MNIST	CNN	0.9915	118.81 s
MNIST	SVM	0.9184	30.23 s
CIFAR10	CNN	0.5297	25.99 s
CIFAR10	SVM	0.2606	185.45 s


在MNIST数据集上，CNN达到了99.15%的极高准确率，而SVM也表现优秀（91.84%）。由于MNIST是灰度图且结构简单、背景纯净，两种算法都能较好地捕捉特征，但CNN凭借卷积核对局部空间结构的感知能力，精准度显著领先；在CIFAR-10数据集上，在同等训练样本（5000张）的情况下，CNN的准确率（52.97%）远高于SVM（26.06%）。

在MNIST上，SVM虽然准确率稍低，但训练速度快（30.23s），体现了处理小规模、低维数据时的便捷性。但在CIFAR-10上，尽管只用了5000张样本，SVM的训练时间却飙升至185.45s，而CNN 仅用25.99s。这说明 SVM 的计算复杂度随特征维度和样本量的增加而剧烈上升，不适合大规模彩色图像任务。

CIFAR-10是彩色图像，包含复杂的背景和物体变形，SVM这种基于原始像素（或简单展平向量）的线性/非线性映射难以处理高维的视觉特征，而CNN通过多层卷积逐渐提取高层语义特征，展示了在复杂视觉任务下的绝对优势。

CNN训练曲线：





从Training Loss曲线看，MNIST和CIFAR-10的损失函数在10个Epoch内均平滑下降并趋于收敛，证明了模型参数设置（Adam优化器、0.001学习率）的合理性。

在Accuracy vs SVM图中可以看到，CNN 的测试准确率从第1个 Epoch 开始就迅速超越了SVM的基准线（红色虚线），并随着迭代持续提升，体现了深度学习强大的学习速率和泛化潜力。

5. 实验总结

本次实验涵盖了从底层特征提取到高层语义分类的完整图像处理流程：通过Sobel算子实现了对图像物理轮廓的敏锐捕捉，理解了梯度信息在特征识别中的基石作用；并通过对比实验直观证明，卷积神经网络CNN凭借其空间结构的层次化特征学习能力，在处理高维彩色图像CIFAR-10时的准确率与计算伸缩性均远超传统线性分类器SVM。这不仅让我深刻体会到深度学习在复杂视觉任务中的绝对优势，也进一步掌握了利用 Python、OpenCV与PyTorch解决实际计算机视觉问题的核心工程技巧。