

# 作业五：股票价格预测

课程：大数据原理与技术

|    |             |        |                                                                            |
|----|-------------|--------|----------------------------------------------------------------------------|
| 年级 | 2023级       | 专业（方向） | 计算机技术与科学                                                                   |
| 学号 | 22344023    | 姓名     | 曾健                                                                         |
| 电话 | 13672733896 | Email  | <a href="mailto:zengj233@mail2.sysu.edu.cn">zengj233@mail2.sysu.edu.cn</a> |

## 1. 实验目标

- 下载某股票历史数据（CSV格式）
- 用ARIMA模型预测未来7天价格
- 用LSTM模型实现相同任务，对比MAE/RMSE指标

## 2. 实验环境

- 硬件环境：
  - 处理器 (CPU): Intel(R) Core(TM) i5-12500H @ 2.30 GHz
  - 图形处理器 (GPU): NVIDIA GeForce RTX 3060 Laptop GPU
  - 运行内存 (RAM): 16.0 GB
- 软件环境：
  - 操作系统 (OS): Windows 11 Home Chinese
  - Python 版本: 3.12

## 3. 算法设计

### 3.1 股票数据

本实验最初尝试通过 `yfinance` 库直接获取YahooFinance的实时行情数据。但在实验过程中发现，由于服务器网络环境限制及接口请求频率限制，频繁出现 `Connection Error` 或远程连接被强制关闭的情况，导致无法稳定获取数据。

为确保实验的可靠性与数据的完整性，最终方案转为使用国内开源金融数据接口库 `akshare`。该库通过爬取主流金融门户（如东方财富、同花顺等）的公开接口，提供了更为稳定的数据支持。本实验分别获取了以下具有代表性的股票样本：

- 美股 (US Stocks)**：苹果公司 (AAPL)、英伟达 (NVDA)
- A股 (China A-Shares)**：贵州茅台 (600519)

## 3.2 算法原理

### 3.2.1 ARIMA模型

差分自回归移动平均模型ARIMA是时序分析中最具代表性的统计模型。它将非平稳的时间序列通过差分转化为平稳序列，再利用历史值和历史误差进行建模。模型由三部分组成：自回归（参数p）、差分（参数q）和移动平均（参数d）。其数学紧凑表达式为：

$$\Phi(B)(1-B)^d y_t = \Theta(B)\varepsilon_t$$

其中：

- $y_t$ 为时间序列在 $t$ 时刻的值
- $B$ 为滞后算子，即 $By_t = y_{t-1}$
- $d$ 为差分阶数，用于使序列平稳
- $\Phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ 是 $p$ 阶自回归多项式，描述当前值与过去 $p$ 个历史值之间的线性关系
- $\Theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ 是 $q$ 阶移动平均多项式，描述当前值与过去 $q$ 个预测误差之间的线性关系
- $\varepsilon_t$ 为白噪声序列

在模型完成参数估计（得到系数 $\phi$ 和 $\theta$ ）后，预测下一步 $\hat{y}_{t+1}$ 的计算公式可以展开为：

$$\hat{y}_{t+1} = \mu + \underbrace{\phi_1 y_t + \dots + \phi_p y_{t-p+1}}_{\text{利用历史观测值}} + \underbrace{\theta_1 \varepsilon_t + \dots + \theta_q \varepsilon_{t-q+1}}_{\text{利用历史预测误差}}$$

本实验通过 `pmdarima.auto_arima` 工具，在设定的参数空间内自动进行网格搜索。模型以AIC准则最小化为目标，自动寻找最匹配当前股票走势的 $(p, d, q)$ 最优阶数组合，从而实现了对复杂金融序列的智能化建模。

### 3.2.2 LSTM模型

长短期记忆网络LSTM是针对传统循环神经网络在处理长序列时易出现的“梯度消失”问题而设计的。其核心在于引入了门控机制来控制信息的累积与遗忘，其内部逻辑可由以下公式组表示：

#### 1. 门控单元计算：

首先，模型通过当前时刻输入 $x_t$ 与上一时刻隐藏状态 $h_{t-1}$ 计算出三个关键的门控信号：

$$\begin{cases} f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) & (\text{遗忘门：控制长时记忆的遗忘程度}) \\ i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) & (\text{输入门：控制新信息的存入程度}) \\ o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) & (\text{输出门：控制短时记忆的输出程度}) \end{cases}$$

#### 2. 记忆细胞更新：

随后，模型计算当前时刻的候选状态 $\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$ ，并更新长时记忆（细胞状态） $C_t$ ：


$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

其中 $\odot$ 表示元素级乘法。这一步实现了对历史信息非线性筛选与补充。

#### 3. 最终输出计算：

最后，模型结合更新后的长时记忆计算出当前时刻的短时记忆（隐藏状态） $h_t$ ，并作为当前单元的预测输出传递至下一层：

$$h_t = o_t \odot \tanh(C_t)$$



CSDN @张小生180

本实验构建了一个两层 LSTM 网络：

```
lstm_model = Sequential([
    Input(shape=(look_back, 1)),
    LSTM(64, return_sequences=True),
    Dropout(0.2, seed=SEED),
    LSTM(32, return_sequences=False),
    Dropout(0.2, seed=SEED),
    Dense(16, activation='relu'),
    Dense(1)
])
```

- **输入层**：采用滑动窗口机制，将过去 `look_back` 天的收盘价作为历史特征输入。
- **特征提取层**：包含两层LSTM。第一层提取高维时序特征并返回完整序列，第二层进一步浓缩核心信息。
- **正则化层**：在两层LSTM后均接入Dropout层，有效防止模型对训练集产生过拟合。
- **输出层**：通过ReLU激活层过渡，最终由单一神经元的全连接层输出下一天的预测价格。

输入特征为过去 `look_back` 天的收盘价序列，预测目标为下一天的收盘价。训练时采用Adam优化器、均方误差损失函数，并引入早停与学习率衰减策略。

### 3.2.3 多步预测机制

由于上述两类模型本质上均为单步预测模型（由  $t$  时刻及前面时刻推导  $t + 1$  时刻），为了满足本实验中对未来7天甚至更长周期的预测需求，本实验统一采用了递归滚动预测策略。即利用已知的历史窗口数据预测  $t + 1$  时刻的价格，将该预测值视作新观测值追加至序列末尾，并相应地更新滑动输入窗口，然后再次调用模型推导出  $t + 2$  时刻的数值。通过这种“预测-回填-再预测”的迭代循环，模型得以生成任意长度的未来趋势曲线。

3.3 评估指标

本实验采用以下两种常用指标：

- MAE平均绝对误差：** $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$ ，该指标直观反映预测值与真实值之间的平均偏差幅度，单位与原数据一致。
- RMSE均方根误差：** $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$ ，该指标对较大的预测误差施加更高惩罚，能够更灵敏地反映模型在个别点上的预测偏差。

4. 实验结果

4.1 实验设置

参数设置

为确保实验可复现，代码中固定了所有随机种子（SEED = 42）。

具体的模型核心超参数设置如下表所示：

| 模型类型  | 关键参数与策略设置                                                                                                                                                                                                                                |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ARIMA | 通过 <code>pmdarima.auto_arima</code> 自动网格搜索最优阶数，以 AIC 准则最小化为目标，最终选择的最优阶数为 $(p, d, q)$ 。                                                                                                                                                   |
| LSTM  | <b>时间窗口：</b> look_back为60天<br><b>网络结构：</b> 双层LSTM（64 单元、32 单元）+ 隐藏层（Dense 16）+ 输出层（Dense 1）<br><b>正则化：</b> 在LSTM层后均加入 <code>Dropout(0.2)</code> 防过拟合<br><b>优化与损失：</b> Adam优化器，MSE损失函数，Batch_Size设为64<br><b>验证集：</b> 时间线末尾10%的样本作为验证集进行测试 |

实验任务


本实验的预测任务跨度分为三个周期：未来7个交易日、未来10个交易日（约两周）以及未来21个交易日（约一个月）。

数据趋势

本实验对以下3个股票（包括美股、A股）进行预测，它们分别是苹果公司AAPL、英伟达NVDA和贵州茅台600519。

AAPL和NVDA的训练数据 2018-01-01 至 2026-03-12 的股价趋势，而贵州茅台为 2015-01-01 至 2026-03-11 的股价趋势，即在模型训练中作为训练集和验证集。2026-03-12 至 2026-04-11 的股价趋势用于预测（下图红线后面的部分），即在模型训练中作为测试集。

3个股票的价格趋势如下：




## 4.2 AAPL预测结果对比


模型训练数据:

ARIMA模型最优阶数为  $(p, d, q) = (0, 1, 0)$

LSTM模型训练曲线:



### 模型预测结果:



通过计算预测值与真实值之间的MAE和RMSE，我们对两种模型在不同预测周期下的表现进行了量化评估。测试集上的误差对比结果如下表所示：


| 预测周期         | ARIMA MAE | ARIMA RMSE | LSTM MAE | LSTM RMSE |
|--------------|-----------|------------|----------|-----------|
| 7个交易日        | 9.4071    | 9.7822     | 3.4276   | 3.9843    |
| 两周 (10个交易日)  | 9.2530    | 9.5282     | 2.6760   | 3.3752    |
| 一个月 (21个交易日) | 7.4071    | 8.3866     | 4.7443   | 5.9900    |

4.3 NVDA预测结果对比


模型训练数据：

ARIMA模型最优阶数为  $(p, d, q) = (5, 2, 0)$

LSTM模型训练曲线：



模型预测结果：



通过计算预测值与真实值之间的MAE和RMSE，我们对两种模型在不同预测周期下的表现进行了量化评估。测试集上的误差对比结果如下表所示：

| 预测周期        | ARIMA MAE | ARIMA RMSE | LSTM MAE | LSTM RMSE |
|-------------|-----------|------------|----------|-----------|
| 7个交易日       | 10.1582   | 11.5013    | 9.8255   | 10.2818   |
| 两周 (10个交易日) | 12.8985   | 14.3009    | 9.1186   | 9.5715    |

| 预测周期         | ARIMA MAE | ARIMA RMSE | LSTM MAE | LSTM RMSE |
|--------------|-----------|------------|----------|-----------|
| 一个月 (21个交易日) | 20.4723   | 22.2705    | 9.3952   | 10.6031   |

4.4 贵州茅台预测结果对比


模型训练数据:

ARIMA模型最优阶数为  $(p, d, q) = (2, 1, 1)$

LSTM模型训练曲线:



模型预测结果:



通过计算预测值与真实值之间的MAE和RMSE，我们对两种模型在不同预测周期下的表现进行了量化评估。测试集上的误差对比结果如下表所示：

| 预测周期         | ARIMA MAE | ARIMA RMSE | LSTM MAE | LSTM RMSE |
|--------------|-----------|------------|----------|-----------|
| 7个交易日        | 47.8808   | 54.6553    | 33.5594  | 36.1028   |
| 两周 (10个交易日)  | 36.1908   | 45.9923    | 28.7294  | 31.6904   |
| 一个月 (21个交易日) | 40.5915   | 47.7216    | 26.7087  | 29.2530   |

### 4.5 结果分析

为了直观对比ARIMA与LSTM在核心任务（未来7天预测）中的表现，我们将三只股票的实验结果汇总如下表：

| 股票名称      | 模型类型  | MAE     | RMSE    |
|-----------|-------|---------|---------|
| AAPL      | ARIMA | 9.4071  | 9.7822  |
| (单位: USD) | LSTM  | 3.4276  | 3.9843  |
| NVDA      | ARIMA | 10.1582 | 11.5013 |
| (单位: USD) | LSTM  | 9.8255  | 10.2818 |
| 贵州茅台      | ARIMA | 47.8808 | 54.6553 |
| (单位: CNY) | LSTM  | 33.5594 | 36.1028 |

从实验得到的各项指标和预测曲线来看，针对作业的7天预测任务，LSTM模型在三只股票上的表现都优于ARIMA模型。

- 误差指标对比：**在AAPL和贵州茅台上，LSTM 的优势非常明显。AAPL的7天MAE仅为3.42，而ARIMA达到了9.40；茅台的LSTM误差也比ARIMA降低了约30%。NVDA由于近期市场波动剧烈，两个模型的误差都相对大一些，但LSTM依然以更小的MAE和RMSE胜出。
- 预测曲线走势：**观察预测图可以发现，ARIMA模型在进行多步预测时，给出的曲线往往趋于一条平滑的直线，这说明它主要捕捉的是序列的整体均值水平，无法应对股价的局部波动。相比之下，LSTM虽然也无法完美预测出每一个转折点，但它的曲线具有一定的起伏，试图去还原历史窗口中的非线性特征。
- 周期跨度的影响：**随着预测时间从7天延长到一个月（21个交易日），两个模型的误差都有所上升。特别是ARIMA在长线预测上基本失效，而LSTM在处理NVDA和茅台的长线趋势时，虽然数值上有偏差，但起码能大致跟上价格波动的节奏。这说明深度学习模型在处理这种复杂、非线性的金融数据时，确实比传统的线性统计模型更具韧性。

## 5. 实验总结

本次实验通过 akshare 接口获取了美股与A股的真实历史行情，并对比了传统ARIMA模型与深度学习LSTM模型在股价预测上的效果。实验过程比较顺利，通过对数据进行归一化处理、设定滑动窗口以及在LSTM中加入早停和Dropout机制，有效地提高了模型的训练效率并防止了过拟合。从最终的实验结果来看，在未来7天到21天的短期预测任务中，LSTM模型在三只股票上的各项指标均全面优于ARIMA模型，验证了神经网络在处理高噪声、非线性时序数据时的强大能力。虽然仅靠历史价格很难实现长期的精准预判，但本次实验成功达成了预定目标，同时使得我深入理解了时序预测的完整流程及不同算法的优缺点。