



中山大學

SUN YAT-SEN UNIVERSITY

多模态大模型课程作业

基于多模态检索增强生成的大型复杂文档理解与智能问答系统研究开题报告

姓名	汤柏祯	学号	23336220
姓名	李贵羽	学号	22344079
姓名	曾健	学号	22344023
学院	计算机学院		
专业	计算机科学与技术		

2026 年 5 月 7 日

摘要

复杂文档理解是多模态大模型落地中较难处理的一类问题。常见的文本 RAG 做法依赖 OCR 把页面展平为线性文本，图表、表格和版面结构往往在这一步被破坏，回答的准确度与可溯源性都会受影响。针对这一点，本课题面向 PDF、扫描件与 PPT 截图，设计并实现一个以页面图像为检索单元的多模态 RAG 系统，让视觉检索、OCR 与多模态生成模型协同工作，完成证据定位与可解释问答。

系统的检索骨干采用 ColPali 类视觉方法，生成端使用 Qwen2.5-VL，并由 PaddleOCR 提供辅助文本通道，整体形成“视觉为主、文本为辅”的双轨结构。实验在 DocVQA、ChartQA、TextVQA 等公开数据集上进行，重点比较纯文本 RAG 与多模态 RAG 在检索召回、答案准确率和忠实度上的差距，以判断视觉原生检索对复杂文档问答的实际收益。课题预期产出可运行的原型系统、一组对比实验结果，以及一份较完整的研究报告。

关键词：多模态大模型；检索增强生成；复杂文档理解；视觉检索；视觉问答；课程开题报告

1 选题背景与研究意义

金融、医疗、教育和工业等领域积累了大量数字文档，里面充斥着表格、图表、公式与复杂排版。这类材料的关键信息并不是一行一行铺在页面上，而是嵌在二维结构里——图表标题对应着图例，表头牵着下方的单元格，脚注又呼应正文里的某句话。一旦用 OCR 把页面拍扁成纯文本，这些空间关系基本就丢了，后续做检索和推理时错位、断章取义几乎是必然结果。

检索增强生成在纯文本问答中已经较为成熟 [1]，但搬到复杂文档上有两个躲不开的问题：检索阶段抓不住页面里的视觉证据，生成阶段对原始版面也缺乏感知，最终回答往往读起来通顺、用起来不可靠。多模态大模型的出现提供了新的思路——直接把页面图像或视觉块作为检索与推理对象，把版面结构保留在系统内。

也就是说，课题想解决的不是“在文档里找一句话”，而是“在复杂文档里把证据结构还原出来，并支撑后续推理”。看财报时要比对去除税收优惠后的利润率变化，看技术文档时要追踪图表与脚注间的引用，看扫描资料时要先恢复版面再定位公式区域——这些任务都需要文本、版面与跨页上下文的综合理解。

从课程层面看，这个题目把多模态模型、向量检索、提示词设计和实验评测串到了一起；从应用层面看，相关做法可以直接用于财报分析、技术手册问答和论文辅助阅读；从研究层面看，纯文本 RAG 与多模态 RAG 的对比能比较直观地说明视觉信息在长文档理解中的作用。系统还强调可溯源——回答时需要交代证据来自第几页、哪张图或哪张表，这一要求让它更接近一个能用的工具，而不是单纯的模型演示。

2 国内外相关工作

2.1 视觉检索与多模态 RAG

文档理解相关研究近几年正在从“先 OCR 后检索”的文本范式转向“直接视觉检索”的多模态范式。ColPali 用视觉语言模型对页面图像编码，配合 Late Interaction 完成细粒度页面检索，在复杂版面场景下的召回效果有明显提升 [7]。VisRAG 走得更远一些，把检索和生成都建立在页面图像之上，避免文档结构在中间环节被反复破坏 [8]。

这些工作传达的共同信号是：复杂文档里的答案不仅依赖文字内容，还依赖版面组织、局部图形和跨区域关系。视觉检索并非 OCR 的替代品，而是换了一种方式表示证据。在扫描模糊、水印遮挡、图表密集和表格跨列这类场景里，直接在视觉空间里检索往往比先还原为线性文本要稳健得多。

2.2 多模态生成模型

生成模型方面，Qwen2.5-VL、Llama 3.2 Vision、DeepSeek-VL 等开源模型在图文理解上都已经具备相当能力 [10, 11, 12]。Qwen2.5-VL 对高分辨率文档、图表和结构化输出处理得比较好，适合作为主力生成模型；Llama 3.2 Vision 上下文窗口更长，可拿来作长文档场景的对比基线；DeepSeek-VL 在中文与逻辑推理上有自己的优势，可作交叉验证用的辅助模型。

放到本课题里，生成模型仅“看懂页面”是不够的，还得能在多页上下文中做归纳、比较、计算和结构化输出。所以模型在文档解析、图表理解、坐标定位和 JSON 输出上的稳定性，比一般的图文对话能力更值得关注。

2.3 工程框架与可复现性

工程实现这一侧，LangChain 与 LangGraph 已经为多模态数据加载、检索编排和问答链构建提供了相对成熟的支撑。配合 PaddleOCR、PyMuPDF、pdf2image 等工具，页面切分、图像预处理、OCR 元数据绑定和检索结果回传都比较好接 [9, 13]。

多向量检索、向量数据库、提示词工程和自动化评测工具之间也已经能拼成一条相对完整的实验链。这意味着课题不仅能做出“跑得起来的演示”，还能进一步开展控制变量对比实验。

2.4 相关工作对本课题的启发

表 1 把上述方法、模型与工程框架放到一起作了简单归纳，也大致勾勒出本课题的定位：视觉检索负责拿到证据，多模态生成模型负责给出答案，OCR 与工程框架把整条链路串起来并保证可复现。

表 1: 相关工作与本课题定位

相关工作/模型	核心特点	对本课题的启发
ColPali	直接对页面图像做多向量检索，适合复杂版面场景	作为多模态检索模块的重要参考
VisRAG Qwen2.5-VL	检索与生成均基于页面图像进行文档解析能力强，适合图表与结构化输出	说明端到端视觉 RAG 的可行性 作为系统主力生成模型
Llama 3.2 Vision	长上下文能力较强	可作为长文档问答对比基线
DeepSeek-VL LangChain / LangGraph	中文与逻辑推理表现较好 便于实现检索、重排与生成编排	可作为辅助模型与备选方案 用于搭建系统整体工作流
PaddleOCR / LayoutParser	支持 OCR、文本框定位和版面分析	用于提取文本、坐标和辅助检索信息
DocVQA / ChartQA	文档问答和图表问答基准数据集	用于实验评测和结果对比

从表 1 可以看出，视觉检索、文档解析模型和 RAG 编排框架已经具备较好的组合基础，因此本课题更关注如何把这些模块整合为一个可演示、可评测的课程项目原型。

3 研究目标与主要内容

3.1 研究目标

本课题打算做出一个面向复杂长文档的多模态问答原型系统，并完成相应的实验验证。除了搭起原型，还要围绕“多模态信息究竟能不能带来增益”这一问题展开比较。具体目标包括：

1. 支持多页 PDF、扫描文档和演示文稿截图的导入与预处理。
2. 构建面向页面图像的多模态检索模块，并保留页码、图号、OCR 文本等元数据。
3. 实现基于多模态大模型的问答生成模块，使回答能够结合图文证据并给出来源定位。
4. 设计纯文本 RAG 与多模态 RAG 的对比实验，评估多模态方案的实际增益。

3.2 主要研究内容

对应上述目标，研究内容拆成四块：

1. **复杂文档数据摄入与表示：**将 PDF 或图像文档转换为页面级图像，并建立页面、块级区域与 OCR 文本之间的关联。
2. **多模态检索模块设计：**以视觉编码与向量索引为基础完成页面级检索，必要时结合 OCR 文本做补充和重排。
3. **多模态问答生成：**把检索得到的页面图像、文本元数据和用户问题一起送入多模态生成模型，输出答案与引用来源。
4. **实验评测与系统分析：**围绕召回率、准确率、忠实度等指标做量化评估，并分析各模块对最终结果的贡献。

对照课程作业题目 3 的要求，本项目最低要做到：支持多页 PDF 或图像输入；支持文本、表格、图形的智能化分块与索引；支持自然语言提问并在答案中给出来源页码；至少在一个公开数据集子集上完成实验，并给出纯文本 RAG 与多模态 RAG 的对比结果。

3.3 功能需求

考虑到最小可行目标和后续的展示需求，把系统功能划分成文档解析、检索问答、引用展示和实验评测几块，详见表 2。这样划分主要是为了把核心验收功能和锦上添花的展示功能分开，免得后期排期时混在一起。

表 2: 系统功能需求

功能模块	需求说明	优先级
文档上传	支持多页 PDF、扫描图片和 PPT 页面截图输入	高
文档解析	完成页面渲染、OCR 识别、版面区域检测和元数据保存	高
多模态分块	区分文本、表格、图像、图表和公式区域，并建立索引单元	高
向量检索	对文本块、图像描述和页面视觉信息进行检索与重排	高
问答生成	基于检索证据生成自然语言答案，减少无依据生成	高
引用定位	输出答案时标注页码、图号、表号或证据区域	高
可视化展示	在页面图中高亮引用区域，提供简单 Web UI	中
实验评测	统计检索召回、答案准确率、引用准确率和响应时间	高

最小可行版本的目标比较直接：用户上传一份多页 PDF 后，系统能完成页面解析、OCR 分块、向量检索和基于证据的问答，并在答案后附上引用页码。在此之上的增强版本会再加入图表区域裁剪、页面高亮、多模态模型直接读图问答，以及纯文本 RAG 与多模态 RAG 的系统性对比实验。

4 系统架构设计

4.1 总体架构设计

系统采用“离线建库 + 在线问答”两段式结构，如图 1。离线阶段处理 PDF、扫描件和 PPT 截图等输入，做页面渲染、OCR 识别、版面信息抽取、多模态向量化与索引构建；在线阶段接收用户问题，依次完成问题编码、混合检索、候选页面重排、多模态生成和答案溯源。把计算量大的文档解析和索引放到离线，在线只负责检索、推理和结果组织，响应延迟和工程实现都会更可控。




图 1: 多模态复杂文档问答系统整体架构图

图 1 中，左侧是文档输入与离线建库流程，把原始文档转化为“页面图像 + OCR 文本 + 版面区域 + 向量表示”这一套统一的知识底座；中间是混合检索与 Top-K 重排，从长文档里定位与问题最相关的页面或区域；右侧是多模态大模型生成与溯源，依据检索证据给出最终回答，并标注页码、图号、表号或区域高亮等可验证来源。

1. **离线建库阶段：**用 PyMuPDF 或 pdf2image 把文档渲染成高分辨率页面图像，再交给 PaddleOCR 提取文本、边界框和版面信息。视觉侧由 ColPali 等多向量检索模型对页面图像进行编码，文本侧保留 OCR 片段、区域坐标与页码元数据，最终一并写入向量数据库与结构化索引。

2. **在线检索阶段：**问题先被向量化，然后在视觉向量库中通过 Late Interaction 召回 Top-K 候选页面，接着借助 OCR 文本、版面区域和关键词匹配做一次轻量重排，以稳住对图表、表格、小字号文本和跨区域信息的定位。
3. **生成与溯源阶段：**系统把用户问题、Top-K 页面图像、相关 OCR 片段和页面元数据组织成多模态上下文，喂给 Qwen2.5-VL 等模型生成回答。输出不止包含结论，还要附上”第 X 页””图 Y””表 Z”或区域高亮等证据来源，方便用户核验。

需要强调的是，系统并不是把页面 OCR 一遍就交给大语言模型，而是始终把”原始页面图像”留作核心证据。OCR 文本用来增强检索和溯源，视觉向量负责保住图表、公式、版式和空间关系。两条通道各干各的活：视觉主通道弥补纯文本 RAG 丢结构的毛病，OCR 辅通道则在小字号文本、专有名词和局部符号上把检索稳住。

4.2 核心模块设计

1. **文档预处理模块：**处理文件读取、页面渲染、图像缩放、页码管理与元数据整理。它的任务是把输入格式统一起来，同时尽量保住原始版面，为下游 OCR、视觉编码和溯源展示打好底。

2. **视觉切块与索引模块：**对应离线建库流程中的视觉编码部分。页面图像被送入视觉编码器做切块和表示学习，形成多向量检索可用的页面表示后写入向量库。条件允许的话，会结合 ColPali 这一类方法做更细粒度的补丁级相似度建模，让问题可以匹配到页面里具体的表格、图像或文本区域。

3. **混合检索与重排模块：**把页面图像当作主要检索对象，回答的是”答案在长文档的哪一页、哪一部分”。问题编码后与候选页面做晚期交互匹配，OCR 文本通道则补上关键词、术语和局部符号的线索；两类信号融合后给出 Top-K 候选页面，作为下游生成的证据。

4. **多模态生成模块：**生成阶段要回答问题、要少出幻觉，还要让答案和证据保持一致。系统通过提示词模板要求模型基于候选页面作答，并明示引用页码与依据。Qwen2.5-VL 同时接收用户问题、Top-K 高分辨率页面图像和 OCR 辅助文本，确保回答时视觉依据与文本线索都在。

5. **溯源与结果组织模块：**把模型输出对回原始页面，整理成”回答 + 证据来源 + 页码/图号/区域位置”的统一格式。这一模块在课程展示里也是最直观的部分，理想输出是”引用：第 X 页，图 Y”或”证据区域：第 X 页表格上半部分”这样的形式。

4.3 技术路线说明

整体路线可以概括为”视觉主通道 + OCR 辅助通道 + 多模态生成”。和纯文本 RAG 相比，区别就在于 OCR 文本不再是唯一的知识来源，页面视觉结构被当作一等信

息来对待。这种设计在图表问答、跨区域引用和复杂表格解析这类任务上应该会更稳一些。

模型方面，Qwen2.5-VL-7B 作为主力生成模型，主要看中它在高分辨率文档、图表和结构化输出上的稳定性；Llama 3.2 Vision 留作长上下文场景的对比方案；DeepSeek-VL 用来补足中文和逻辑推理。OCR 选 PaddleOCR，中文版面效果和工程可复现性都比较平衡。检索侧采用视觉切块加多向量表示，关键的匹配机制是 Late Interaction，让问题能匹配到页面的局部视觉证据，而不只是整页的相似度。




图 2: 文档页面多模态分块示意图占位

图 2 展示了系统如何把一页复杂文档拆成可检索的结构化单元，对应表 2 里的”多模态分块”和”引用定位”模块，也是后续做证据定位和页面高亮的基础。

4.4 模型与工具选型

按照上面的技术路线，各模块计划用到的工具和备选方案汇总在表 3 中。优先用成熟开源工具完成集成，万一算力或环境吃紧再切到轻量方案。

表 3: 模型与工具选型

模块	首选工具/模型	备选方案
页面渲染	PyMuPDF / pdf2image	LibreOffice 转 PDF 后处理
OCR	PaddleOCR	Tesseract
版面分析	PP-Structure / LayoutParser	基于规则的区域划分
视觉检索	ColPali 类页面级视觉检索	图像描述向量检索、CLIP 检索
多模态模型	Qwen2.5-VL-7B-Instruct	DeepSeek-VL、Llama 3.2 Vision、 云端 API
文本嵌入	bge-small-zh-v1.5 / bge-m3	text2vec、OpenAI Embeddings
向量数据库	FAISS / Chroma	Milvus
编排框架	LangChain / LangGraph	LlamaIndex
演示界面	Gradio / Streamlit	FastAPI + Vue

可以看出，课题并不打算从零训练大模型，而是围绕页面解析、视觉检索和多模态生成做工程组合，这也是把实现风险压在课程周期内的关键考虑。

5 实验设计与评测方案

5.1 数据集选取

实验语料计划使用下面几个数据集或其子集：

- **DocVQA**：测试复杂文档页面中的文字定位与问答能力 [2]。
- **ChartQA**：测试图表数据的读取、比较与计算能力 [3]。
- **TextVQA**：作为辅助测试集，观察 OCR 增强模块的泛化表现 [4]。
- **自建课程文档集**：收集课程 PPT、作业说明 PDF、论文 PDF、扫描件和带图表的报告，人工设计问题并标注答案和证据页码。

DocVQA 主要考察复杂页面里的关键信息抽取，ChartQA 检验模型对图表数值关系的理解，TextVQA 则用来看 OCR 辅助通道在非标准排版下的适应能力，三者放在一起基本能覆盖文本、图表和视觉结构这三类问题。自建数据集初步打算收 8–12 份不同类型的文档，每份设计 5–10 个问题，整体约 60–120 条问答样本。

5.2 对比实验设计

为了检验多模态方案是否真的有用，准备搭两组系统做对比：

- **基线组：纯文本 RAG。**先做 OCR 与文本分块，再用文本向量模型检索相关内容，最后由大模型生成答案。
- **实验组：多模态 RAG。**保留原始页面图像做视觉检索，生成阶段把页面图像和 OCR 辅助信息一起送入模型。

实验时尽量控制变量一致——测试样本、问题集合、生成模型配置、回答格式都保持相同，这样得到的对比才有说服力。初步打算在 DocVQA 与 ChartQA 中抽出统一的测试子集，分别跑两套系统，统计检索指标和答案指标，并挑一些典型失败案例分析 OCR 把版面拍扁后到底丢了什么。




图 3: 纯文本 RAG 与多模态 RAG 对比实验流程图占位

图 3 用来说明实验中变量是怎么控制的：两组系统使用同一套问题和指标，只改证据表示与检索生成链路，这样能更直接地观察多模态信息带来的增益。

表 4: 实验设计与评价指标

实验对象	对比方法	评价指标	预期观察
检索效果	OCR 文本检索 vs 混合检索	Recall@1/3/5、MRR	混合检索在图表和跨页问题上召回更稳定
问答效果	纯文本 RAG vs 多模态 RAG	Accuracy、F1、ANLS、人工评分	多模态 RAG 在图表、表格和版面问题上更准确
引用定位	无引用输出 vs 页码/区域引用	引用准确率、可核验性	引用输出可降低幻觉并提升可信度
系统效率	不同 Top-K 和不同模型配置	平均响应时间、显存占用	在准确率和速度之间选择适合展示的配置

表 4 把对比实验拆成检索、问答、引用、效率四层。这样不仅能看出最终答案是否正确，还能判断错误到底出在检索召回、证据排序还是生成环节。

5.3 评测指标

为了尽量完整地反映系统表现，计划用到下面这些指标：

- **Recall@K**: 检索阶段是否能找回正确的证据页面。
- **NDCG@5**: 候选页面排序的质量。
- **ANLS**: 问答答案与标准答案之间的相似度。
- **Relaxed Accuracy**: 图表数值问答任务的数值正确性。
- **Faithfulness / Relevance**: 答案是否忠于检索到的上下文。

如果时间和算力允许，还会引入 RAGAS 这类自动评测方法，对多模态相关性、上下文精度和答案忠实度做辅助评估，让结论更扎实一些 [15]。

5.4 错误分析

实验跑完后会对失败案例做分类分析，重点关注下面这几类：

1. OCR 识别有误导致文本证据残缺；
2. 表格结构解析出错让指标和单元格对不上；
3. 检索没召回正确的页面或区域；

4. 生成模型绕开证据自己编；
5. 图表数值读取或计算出错；
6. 多页上下文拼接时证据相互冲突。

6 项目可行性分析

6.1 技术可行性

技术路线建立在比较成熟的开源工具和公开模型之上，整体实现风险可控。文档解析这一侧，PyMuPDF 和 pdf2image 已经能稳定完成 PDF 渲染与图片转换，PaddleOCR 提供中文 OCR、文本框坐标和基础版面信息，足够给下游检索与溯源用。检索这一侧，FAISS、Chroma 这类向量库支持页面级和片段级索引，ColPali 也给”直接检索页面图像”提供了可以参考的实现路径。生成这一侧，Qwen2.5-VL 等多模态模型在文档图像理解、图表识别和中文问答上的表现已经能撑起主力生成模型的位置。

从工程角度看，整个项目可以切成文档预处理、索引构建、混合检索、多模态问答、引用溯源和实验评测几个相对独立的模块，三人小组能并行推进。就算部分高级功能没能一次性做出来，也可以先把”PDF 上传—页面解析—Top-K 检索—基于证据的问答—页码引用”这条最小链路跑通，再补充区域高亮、图表定位和多模型对比。因此课程周期内的可行性是有的。

6.2 算力可行性

考虑到硬件条件有限，课题优先选 7B 量级的开源多模态模型，配合量化推理、分辨率控制、限制 Top-K 页面数和分阶段运行等手段把显存压下来。复杂实验先在小规模样本上把链路跑通，再扩大测试集，这样能在实验完整性和计算成本之间取个平衡。

如果按单卡 24GB 显存来估算，同时把生成模型、视觉检索编码器和较大规模缓存加载到一起会比较吃力。因此实现时优先保证核心链路稳定：离线阶段分批做页面编码和向量入库，在线阶段控制候选页面数量与输入图像分辨率；本地推理压力实在过大，就切到云端 API 或者更小的模型上。

6.3 风险与应对

表 5 列出了实现过程中可能踩到的主要风险和对应的应对策略，主要是给后续开发排期做参考——一旦算力、数据或模型效果不理想，可以及时切到备选方案。

表 5: 项目风险与解决策略

风险	影响	应对策略
OCR 对扫描件识别较差	检索证据缺失或答案错误	保存原始页面图，必要时调用 VLM 直接读图
视觉语言模型显存不足	Demo 响应慢或无法运行	使用量化模型、降低分辨率、限制 Top-K 或调用云端 API
向量检索召回不准	生成模型无法获得正确证据	引入关键词检索、重排器和标题页码元数据
答案出现幻觉	系统可信度下降	提示词强制要求引用证据，无证据时拒答
实验数据不足	结果说服力较弱	提前构建 60-120 条 QA 样本，并补充 DocVQA/ChartQA 子集

主要风险集中在 OCR 质量、视觉模型算力消耗和检索召回稳定性三个方面。因此推进策略是先把最小可运行系统拿下，再逐步增强视觉检索、区域级定位和实验评测，避免在某一个高难度模块上耗太久而拖累整体交付。

7 项目实施计划

7.1 项目进度安排

项目按照 8 周的课程周期推进，阶段安排见表 6。节奏上是”先把基础链路跑通，再补多模态增强与实验评测”，避免最后阶段集成出岔子。

表 6: 项目进度计划

阶段	时间安排	主要任务
阶段一	第 1 周	阅读文献，明确任务范围，完成数据集与模型选型。
阶段二	第 2-3 周	完成文档预处理、OCR 管道与页面级数据组织。
阶段三	第 4-5 周	搭建多模态检索与问答原型，完成基础联调。
阶段四	第 6 周	实现可溯源问答输出，补充提示词与结果格式。
阶段五	第 7 周	开展纯文本 RAG 与多模态 RAG 对比实验。
阶段六	第 8 周	整理实验结果，撰写课程报告并准备展示材料。

第 4-6 周是系统集成的关键阶段，第 7 周集中完成纯文本 RAG 与多模态 RAG 的对比实验。

7.2 小组分工

项目由三人小组协作完成，按”数据与检索、模型与问答、实验与报告”三条线分工，初步安排见表 7，后续视进展再调整。

表 7: 三人小组建议分工

成员	建议负责方向	主要工作内容
汤柏祯	数据处理与工程搭建	数据集整理、PDF 页面切分、OCR 处理、元数据组织与基础接口搭建。
李贵羽	检索与生成模块	多模态检索模块接入、向量检索调试、提示词设计与问答链路实现。
曾健	实验评测与文档撰写	基线系统搭建、对比实验设计、指标统计、图表绘制与最终报告整合。

7.3 预期成果

1. 一个可运行的复杂文档多模态问答原型系统，支持上传多页 PDF 或图片并进行自然语言问答。
2. 一条多模态文档索引流水线，覆盖页面渲染、OCR、分块、图表描述、向量入库和元数据管理。
3. 一个带引用来源的问答模块，输出答案、依据、页码和图号等信息。
4. 一组纯文本 RAG 与多模态 RAG 的对比实验结果。
5. 若干成功与失败案例的分析，用来说明系统的优势、局限和后续改进方向。
6. 一份结构完整、格式规范的开题报告与后续结题材料。

8 结论

课题聚焦复杂文档理解这个研究价值和应用价值都比较实在的方向，试图通过视觉检索与多模态生成的结合，弥补纯文本 RAG 在版面结构保留和图表理解上的不足。对于三人课程项目来说，这个题目挑战性合适，又能拆成几个相对清晰的工程模块，适合按阶段迭代推进。如果对比实验能验证多模态方案相对纯文本方案的优势，课题在课程展示和实际意义上都会有一定的落点。

参考文献

- [1] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. arXiv:2005.11401, 2020. <https://arxiv.org/abs/2005.11401>
- [2] Mathew M, Karatzas D, Jawahar C V. DocVQA: A Dataset for VQA on Document Images[EB/OL]. arXiv:2007.00398, 2020. <https://arxiv.org/abs/2007.00398>
- [3] Masry A, Long D X, Tan J Q, et al. ChartQA: A Benchmark for Question Answering about Charts with Visual and Logical Reasoning[EB/OL]. arXiv:2203.10244, 2022. <https://arxiv.org/abs/2203.10244>
- [4] Singh A, Natarajan V, Shah M, et al. Towards VQA Models That Can Read[EB/OL]. arXiv:1904.08920, 2019. <https://arxiv.org/abs/1904.08920>
- [5] Huang Y, Lv T, Cui L, et al. LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking[EB/OL]. arXiv:2204.08387, 2022. <https://arxiv.org/abs/2204.08387>
- [6] Shen Z, Zhang K, Dell M. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis[EB/OL]. arXiv:2103.15348, 2021. <https://arxiv.org/abs/2103.15348>
- [7] Faysse M, Sibille H, Wu T, et al. ColPali: Efficient Document Retrieval with Vision Language Models[EB/OL]. arXiv:2407.01449, 2024. <https://arxiv.org/abs/2407.01449>
- [8] Yu S, Tang J, Xu H, et al. VisRAG: Vision-based Retrieval-Augmented Generation on Multi-modality Documents[EB/OL]. arXiv:2410.10594, 2024. <https://arxiv.org/abs/2410.10594>
- [9] PaddleOCR Project. PaddleOCR Documentation and Repository[EB/OL]. <https://github.com/PaddlePaddle/PaddleOCR>
- [10] Qwen Team. Qwen2.5-VL Technical Report[EB/OL]. arXiv:2502.13923, 2025. <https://arxiv.org/abs/2502.13923>
- [11] Meta AI. Llama 3.2 Vision Official Introduction[EB/OL]. <https://ai.meta.com/blog/llama-3-2-connect-2024-vision-edge-mobile-devices/>

- [12] Lu H, Liu W, Zhang B, et al. DeepSeek-VL: Towards Real-World Vision-Language Understanding[EB/OL]. arXiv:2403.05525, 2024. <https://arxiv.org/abs/2403.05525>
- [13] LangChain. Visual QA and Multimodal Retrieval Documentation[EB/OL]. https://python.langchain.com/docs/use_cases/visual_qa
- [14] Johnson J, Douze M, Jegou H. Billion-scale similarity search with GPUs[EB/OL]. arXiv:1702.08734, 2017. <https://arxiv.org/abs/1702.08734>
- [15] Es S, James J, Espinosa-Anke L, Schockaert S. RAGAS: Automated Evaluation of Retrieval Augmented Generation[EB/OL]. arXiv:2309.15217, 2023. <https://arxiv.org/abs/2309.15217>